

Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- Función de coste
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Clasificación

Ejemplo en el sector eléctrico

- La empresa está impulsando la transición al vehículo eléctrico. Para ello tiene una política de marketing que se dirige captar nuevos usuarios entre sus clientes.
 - Dado el coste de dicha política, la acción comercial no se dirige a todos los clientes de manera universal, sino sólo a aquéllos que son potenciales compradores.
 - ¿El nuevo cliente es uno de ellos?
- Para dilucidarlo se plantea distintas cuestiones previas


Clasificación

Ejemplo en el sector eléctrico

- La primera cuestión es saber si el cliente tiene o no garaje propio. Ese dato no consta en sus bases de datos, por lo que realiza un muestreo entre sus clientes.
- De este muestreo obtiene dos datos
 1. Superficie de la vivienda (m^2)
 2. Tiene garaje (Si/No)
- Con esa información quiere inferir si un determinado cliente tiene garaje en función del tamaño de su vivienda (dato que sí consta en sus bases de datos)


Regresión logística

3. Formulación de hipótesis



Regresión logística

3. Formulación de hipótesis




w_0, w_1
calculados
por regresión
lineal

$$h_w(x) = w_0 + w_1x$$

Regresión logística

3. Formulación de hipótesis




w_0, w_1
calculados
por regresión
lineal

$$h_w(x) = w_0 + w_1x$$

Regresión logística

3. Formulación de hipótesis



$$w_0 = -100$$

$$h_w(x) = \frac{1 + \text{sign}(x + w_0)}{2}$$

Regresión logística

5. Optimización del coste


$$h_w(x) = \frac{1 + \text{sign}(x + w_0)}{2}$$

$$\frac{d}{dw} J(h_w(x), y) = 0$$

La función $\text{sign}(x)$ no es derivable (en el origen)

Regresión logística

3. Formulación de hipótesis



$$\frac{w_0}{w_1} = -100$$

Función
logística

$$h_w(x) = \frac{1}{1 + e^{-z}}$$

$$z \equiv w_0 + w_1 x$$

Regresión logística

3. Formulación de hipótesis

Cuota (odds) $o \equiv \frac{p}{1-p}$ p : probabilidad de que tenga garaje

Log-odds $Ln(o) = z = w_0 + w_1x$ Unida de medida: logit (logistic unit)


Puede usarse otra función no lineal $z = f(x)$ (p.e. polinómica)

$$o = e^z = e^{(w_0 + w_1x)}$$

$$p = \frac{o}{1+o} = \frac{1}{1+o^{-1}} = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(w_0+w_1x)}}$$

Regresión logística

3. Formulación de hipótesis



$$\frac{w_0}{w_1} = -100$$

Otras
sigmoides

$$h_w(x) = \frac{1}{2} + \frac{\text{atan}(z)}{\pi}$$

$$z \equiv w_0 + w_1 x$$


Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- **Función de coste**
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Regresión logística

4. Elección de la función de coste

Hipótesis:
Función
logística



$$w_1 = 1$$


Coste
cuadrático
No convexo

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión logística

4. Elección de la función de coste

Hipótesis:
Función
logística



$$w_0 = -100$$

Coste
cuadrático
No convexo

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión logística

4. Elección de la función de coste

Función de coste 0-1

$$\hat{y} = \begin{cases} 1, & h_w(x) \geq t_h \\ 0, & h_w(x) < t_h \end{cases} \quad t_h = 0.5$$



$$I(u) \equiv \begin{cases} 1, & u = \textit{True} \\ 0, & u = \textit{False} \end{cases}$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n I(\hat{y}^{(i)} \neq y^{(i)}) = ACC$$

$$ACC \equiv \frac{\text{\#aciertos}}{n}$$

Regresión logística

4. Elección de la función de coste



Coste 0-1

No convexo

Regresión logística

4. Elección de la función de coste

Función de coste logística (cros-entropía)


$$e(h_w(x), y) = |h_w(x) - y|$$

$$L(h_w(x), y) = -Ln(1 - e)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

Regresión logística

4. Elección de la función de coste



$$L(h_w(x), y) = -\ln(1 - e)$$

Regresión logística

4. Elección de la función de coste

Función de coste logística (cros-entropía)

$$e = |h_w(x) - y| = \begin{cases} 1 - h_w(x), & \forall y = 1 \\ h_w(x), & \forall y = 0 \end{cases}$$


$$L(h_w(x), y) = -\text{Ln}(1 - e) = \begin{cases} -\text{Ln}(h_w(x)), & \forall y = 1 \\ -\text{Ln}(1 - h_w(x)), & \forall y = 0 \end{cases}$$

$$L(h_w(x), y) = -y\text{Ln}(h_w(x)) - (1 - y)\text{Ln}(1 - h_w(x))$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

Regresión logística



4. Elección de la función de coste



$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

Regresión logística

4. Elección de la función de coste




Función de coste logística (cros-entropía)

CONVEXA

Regresión logística

4. Elección de la función de coste



Función de coste logística (cros-entropía)
CONVEXA

Regresión logística

4. Elección de la función de coste

Función de coste logística con regularización

$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

Regresión logística

5. Optimización del coste

Normal Equation

$$w^* = \arg \min_w J(h_w(x), y)$$

$$\nabla_w J(h_w(x), y) = 0$$

$$\nabla_w \frac{1}{n} \sum_{i=1}^n \text{Loss}(h_w(x^{(i)}), y^{(i)}) = 0$$

$$\sum_{i=1}^n \nabla_w \text{Loss}(h_w(x^{(i)}), y^{(i)}) = 0$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\sum_{i=1}^n \nabla_w - \text{Ln} \left(1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)}) \right) = 0$$

$$\sum_{i=1}^n \frac{(2y^{(i)} - 1)(\nabla_w h_w(x^{(i)}) - y^{(i)})}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0$$

$$h_w(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\nabla_w h_w = \begin{bmatrix} \frac{\partial h_w}{\partial w_0} & \frac{\partial h_w}{\partial w_1} \end{bmatrix}$$

$$\frac{\partial h_w}{\partial w_0} = \frac{-1}{(1 + e^{-(w_0 + w_1 x)})^2} e^{-(w_0 + w_1 x)} (-1)$$

$$\frac{\partial h_w}{\partial w_1} = \frac{-1}{(1 + e^{-(w_0 + w_1 x)})^2} e^{-(w_0 + w_1 x)} (-x)$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\begin{cases} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{\partial h_w(x^{(i)})}{\partial w_0} - y^{(i)} \right)}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{\partial h_w(x^{(i)})}{\partial w_1} - y^{(i)} \right)}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0 \end{cases}$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\left\{ \begin{array}{l} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{x^{(i)} e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \end{array} \right.$$

Regresión logística

5. Optimización del coste


Normal Equation

$$\left\{ \begin{array}{l} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})} - y^{(i)} \right)} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \end{array} \right.$$

Sin solución analítica

Regresión logística

5. Optimización del coste



$$w_0^* = -15.2$$
$$w_1^* = 0.155$$

Gradient Descent

Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- Función de coste
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Regresión logística

6. Evaluación del resultado

$$n_{train} = 10$$

$$t_h = 0.5$$

Cliente	Superficie (m ²) $x^{(i)}$	Garaje $y^{(i)}$	Predicción $h^{(i)}$	Garaje $\hat{y}^{(i)}$
11	139	S	0.998	S
12	54	N	0.001	N
13	96	S	0.428	N
14	95	N	0.372	N
15	132	S	0.994	S
⋮	⋮	⋮	⋮	⋮

$$h_w(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

$$\hat{y} = \begin{cases} 0, & \forall h_w(x) < t_h \\ 1, & \forall h_w(x) \geq t_h \end{cases}$$

Regresión logística

6. Evaluación del resultado

Matriz de confusión

		Clase calculada		Elementos
		P	N	
Clase real	P	TP	FN	n_P
	N	FP	TN	n_N
Estimaciones		e_P	e_N	n

		Clase calculada		Elementos
		P	N	
Clase real	P	545	46	591
	N	77	322	399
Estimaciones		622	368	990


Regresión logística

6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Valor
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.9222
Specificity	SPC	$\frac{TN}{TN + FP}$	0.8070
Precision	PRC	$\frac{TP}{TP + FP}$	0.8762
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.8750
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.8758
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.8986
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.8627



Regresión logística

6. Evaluación del resultado




Regresión logística

6. Evaluación del resultado




Regresión logística

6. Evaluación del resultado



Regresión logística


6. Evaluación del resultado



Receiver operating characteristic (ROC)

Regresión logística

6. Evaluación del resultado




Area Under Curve (AUC)

$$AUC = 0.9519$$

Regresión logística


6. Evaluación del resultado



Elección del umbral de decisión
Datos de validación

Regresión logística


6. Evaluación del resultado



Elección del umbral de decisión
Datos de validación

Regresión logística

6. Evaluación del resultado



Curva de aprendizaje